

CHAPTER · ENSEMBLE I

앙상블 : Bagging 과 Random Forest 나무 한 그루보다 숲

불안정한 트리 여러 개를 평균하면 왜 더 좋아질까? 평균의 힘 (분산 감소) 과 다양성 (낮은 상관) 의
중요성

Decision Tree (CART) 다음 시간 · Bootstrap · OOB · 변수 중요도 · randomForest 실습

학습 목표

1 예측오차의 분해

예측오차 = 잡음 + $\text{Bias}^2 + \text{Variance}$ 로 나누어 모형의 약점을 진단할 수 있다 .

2 평균의 힘

여러 모형을 평균하면 bias 는 그대로 , variance 는 작아져 예측오차가 줄어드는 이유를 설명할 수 있다 .

3 Bagging

부트스트랩으로 여러 트리를 만들고 결합하는 과정과 OOB 오차를 이해한다 .


4 Random Forest 와 다양성

트리 간 상관 (ρ) 을 낮추는 것이 왜 중요한지 , mtry 가 그 역할을 어떻게 하는지 설명하고 R 로 실습한다 .

단일 트리의 약점 : 불안정하다 (high variance)


학습 데이터가 조금만 달라져도 첫 분할부터 달라지고, 그 아래 트리 전체가 바뀐다

학습 데이터 A



→ 같은 x 에 대한 예측값이 크게 달라짐

학습 데이터 A' (몇 개 관측치만 다름)



→ “모형 자체” 가 흔들리는 것 = 분산 (variance) 이 큼

오늘의 질문 : 트리의 장점 (낮은 bias, 비선형 · 상호작용 포착) 은 살리고, 흔들림 (variance) 만 줄일 수 있을까 ?

예측오차는 세 부분으로 나뉜다

$$E[(Y - \hat{y}(x))^2] = \sigma^2 + \text{Bias}^2[\hat{y}(x)] + \text{Var}[\hat{y}(x)]$$

σ^2 : 줄일 수 없는 오차

Irreducible error

데이터 자체의 잡음 . 어떤 모형도 없앨 수 없음

Bias^2 : 편향

Bias

평균적으로 정답에서 얼마나 벗어나는가 .
모형이 너무 단순하면 큼 (과소적합)

Variance : 분산


Variance

학습 데이터가 바뀔 때 예측이 얼마나 흔들리는가 . 모형이 너무 복잡하면 큼 (과대적합)

우리가 줄일 수 있는 부분 = $\text{Bias}^2 + \text{Variance}$ → 둘 중 하나를 줄이되 , 다른 하나를 키우지 않는 것이 핵심


과녁으로 보는 Bias 와 Variance

● 빨간 점 = 정답 , ● 파란 점 = 서로 다른 학습 데이터로 만든 모형들의 예측




낮은 Bias · 낮은 Variance

이상적




낮은 Bias · 높은 Variance

깊은 트리 한 그루



높은 Bias · 낮은 Variance

너무 작은 트리



높은 Bias · 높은 Variance

최악

깊은 트리 = 평균적으로는 정답 근처 (낮은 bias) 지만 크게 흩어짐 (높은 variance). **흩어진 점들의 “평균” 을 쓰면 과녁 중앙에 가까워진다 !**

평균의 힘 : 평균을 취하면 분산이 작아진다

$Z_1, \dots, Z_B$ 가 서로 독립, 각각 분산 σ^2 이면


$$\text{Var}(\bar{Z}) = \sigma^2 / B$$

일상의 예 : 군중의 지혜

골턴의 황소 무게 맞추기 (1906): 한 사람 한 사람의 추측은 제각각이었지만, 800 명 가까운 추측을 모으면 실제 무게와 1% 이내로 맞았다.

개인의 오차가 서로 상쇄되기 때문

평균의 분산 (한 개일 때 = 100%)



예측 모형도 마찬가지 : 흔들리는 예측 여러 개를 평균하면 흔들림이 상쇄된다

평균하면 Bias 는 그대로 , Variance 는 작아진다

$$\text{앙상블 예측 : } \hat{y}_{\text{bag}}(\mathbf{x}) = (1/B) \sum_{b=1..B} \hat{y}_b(\mathbf{x})$$

Bias

$$E[\hat{y}_{\text{bag}}] = E[\hat{y}_b]$$

평균의 기댓값 = 개별 모형의 기댓값 →
Bias 변하지 않음

Variance

$$\text{Var}[\hat{y}_{\text{bag}}] = \text{Var}[\hat{y}_b] / B$$

(모형들이 독립이라면) B 배 작아짐

예측오차

$$\sigma^2 + \text{Bias}^2 + \text{Var} / B$$

줄일 수 있는 오차 중 Variance 부분이
사라진다

결론 : bias 는 낮지만 variance 가 큰 모형 (깊은 트리) 일수록 평균의 효과가 크다

문제 : 학습 데이터는 하나뿐이다

이상적인 경우

모집단에서 학습 데이터를 B 번 새로 뽑아 → 트리 B 개 → 평균



✗ 현실에서는 불가능

해결책 : 부트스트랩 (Bootstrap)

가진 데이터 하나에서 “복원추출” 로 비슷한 데이터셋을 여러 개 만들어 낸다



✓ Bootstrap AGGREGATING = Bagging

Bagging (Breiman, 1996) = 부트스트랩 표본마다 모델을 만들고 (bootstrap) 그 결과를 모은다 (aggregating)

부트스트랩 : n 개에서 n 개를 복원추출

원래 데이터



표본 1



OOB:



표본 2



OOB:



표본 3



OOB:



OOB

Out-Of-Bag: 그 표본에 한 번도 뽑히지 않은 관측치


약 63.2%

각 부트스트랩 표본에 들어가는 서로 다른 관측치 비율

약 36.8%

뽑히지 않는 (OOB) 관측치 비율 : $(1 - 1/n)^n \rightarrow e^{-1} \approx 0.368$

Bagging 알고리즘



1 부트스트랩

B 개의 부트스트랩 표본 생성

2 깊은 트리

각 표본으로 가지치기 없이 크게 트리 적합

3 결합

회귀 : 평균 · 분류 : 다수결 (또는 확률 평균)

Bagging 의 세부 사항

1 가지치기를 하지 않는다

개별 트리는 일부러 크게 키운다 → bias 낮게 . 커진 variance 는 평균이 해결

2 회귀 vs 분류

회귀 : B 개 예측값의 평균 · 분류 : B 개 트리의 다수결 투표 (또는 클래스 확률을 평균한 뒤 가장 큰 클래스)

3 B 는 크게 해도 괜찮다


트리 수를 늘려도 과대적합되지 않고 오차가 수렴할 뿐 . 보통 수백 개 (계산 시간과 타협)

4 해석 방법이 달라진다

트리 수백 개의 평균은 트리 그림 한 장으로 읽을 수 없다 → 변수 중요도 (VIP) 와 부분 의존도 (PDP) 로 해석 (뒤에서)

Bagging 은 트리뿐 아니라 어떤 모형에도 적용 가능 — 불안정한 (분산이 큰) 모형일수록 효과가 크다

실제로 확인 : 평균하면 Variance 가 줄어든다



Variance

7.91 → 1.06

평균하자 분산이 약 87% 감소

Bias²

3.56 → 3.8

bias 는 거의 그대로


예측오차

12.47 → 5.86

전체 오차가 절반 이하로

시뮬레이션: Friedman #1 데이터 ($p = 10$, 그중 5 개는 잡음 변수, $\sigma^2 = 1$), 학습 데이터 $n = 300$ 을 40 번 새로 뽑아 반복. 테스트 400 개 점에서 계산 (Python scikit-learn).

트리 수 (B) 가 늘수록 예측오차가 줄고 수렴한다



B = 1

트리 1 개 (부트스트랩 표본 → 원래 트리보다 약간 나뻐)

B = 10

이미 오차가 절반 가까이로

B ≥ 100

거의 평평 : 더 늘려도 과대적합 없이 수렴

x 축 간격은 균등하지 않음 (1, 2, 3, 5, 10, 20, 30, 50, 100, 200). 시뮬레이션 설정은 앞 슬라이드와 동일.

OOB 오차 : 공짜로 얻는 테스트 오차

각 관측치는 약 1/3 의 트리에서 학습에 쓰이지 않았다 → 그 트리들로만 예측하면 “처음 보는 데이터” 에 대한 예측

	T1	T2	T3	T4	T5	T6	T7	T8
관측치 1	■	■	■	■	■	■	■	■
관측치 2	■	■	■	■	■	■	■	■
관측치 3	■	■	■	■	■	■	■	■
관측치 4	■	■	■	■	■	■	■	■
관측치 5	■	■	■	■	■	■	■	■
관측치 6	■	■	■	■	■	■	■	■

■ 학습에 사용 (in-bag) ■ OOB

예 : 관측치 3

T1, T4, T7 은 관측치 3 을 보지 못했다 → 이 세 트리의 예측만
평균해 $\hat{y}_3^{OOB}$ 계산

모든 관측치에 대해 반복


$$OOB\ MSE = (1/n) \sum (y_i - \hat{y}_i^{OOB})^2$$

별도의 test set 이나 CV 없이도 예측오차를 추정 (B 가 크면
leave-one-out CV 와 거의 같음)


Bagging 의 한계 : 트리들이 서로 닮았다

아주 강한 예측변수가 하나 있으면 , 거의 모든 부트스트랩 트리가 그 변수로 첫 분할을 한다


Bagging 트리 1



Bagging 트리 2



Bagging 트리 3



→ 모양이 비슷한 트리 = 예측값도 비슷 = 서로 높은 상관 (ρ 가 큼)

앞의 “ σ^2/B ” 는 트리들이 독립일 때의 이야기 . **트리들이 닮아 있으면 아무리 많이 평균해도 분산이 충분히 줄지 않는다**

상관이 있는 것들의 평균 : 분산에 바닥이 생긴다

$$\text{Var}(\bar{Z}) = \rho\sigma^2 + (1 - \rho)\sigma^2 / B$$

$Z_1, \dots, Z_B$ 각각 분산 σ^2 , 서로 간 상관계수 ρ (트리 b 의 예측 = Z_b)

$$(1 - \rho)\sigma^2 / B$$

B 를 늘리면 0으로 $\rightarrow$ 트리를 많이 만들면 사라지는 부분

$$\rho\sigma^2$$

B 를 아무리 늘려도 남는 “바닥” $\rightarrow$ 줄이려면 ρ 를 낮춰야 한다


$$\rho = 0 \text{ 이면}$$

σ^2 / B : 앞에서 본 독립인 경우 (최고의 상황)

$$\rho = 1 \text{ 이면}$$

σ^2 : 똑같은 트리 B 개 = 트리 1개. 평균 효과 없음

ρ 에 따라 평균의 효과가 얼마나 달라지나 ?



$\rho = 0.8$

B = 50 이어도 분산은 80% 이상 남음

$\rho = 0.2$

분산이 20% 수준까지 내려감

핵심

트리 “수” 보다 트리 간 “다양성 (낮은 ρ)” 이 바닥을 결정

$\rho\sigma^2 + (1 - \rho)\sigma^2/B$ 를 $\sigma^2 = 1$ 로 두고 그린 이론 곡선

다양성은 왜 중요한가 ?

같은 생각을 하는 100 명

모두 같은 교과서 , 같은 선생님에게 배운
100 명에게 물으면 → 틀릴 때 다 같이
틀린다 . 100 명의 의견 $\approx$ 1 명의 의견

서로 다른 100 명

배경과 관점이 다른 100 명 → 각자의
실수가 서로 다른 방향 → 평균하면
상쇄된다 (군중의 지혜의 전제 조건)

분산 투자 (포트폴리오)

같이 오르내리는 주식 10 개를 사면
위험이 그대로 . 서로 상관이 낮은 자산을
섞어야 위험 (분산) 이 줄어든다

좋은 앙상블의 두 조건

- ① 개별 모형이 어느 정도 정확할 것 ② 모형들이 서로 “다르게” 틀릴 것 (낮은 상관)

Random Forest: 트리에 일부러 “다양성” 을 주입한다

Bagging + 분할할 때마다 설명변수 p 개 중 m 개만 무작위로 골라, 그 안에서만 최적 분할을 찾는다



이번 분할의 후보 : X_2, X_7, X_9 ($m = 3$) — 다음 분할에서는 또 새로 뽑는다

$$m = p$$

모든 변수를 후보로 → Bagging 과 동일

$$m \approx \sqrt{p}$$

분류 문제의 관례적 기본값

$$m \approx p / 3$$

회귀 문제의 기본값 (R randomForest)

효과 : 강한 변수가 매번 첫 분할을 독점하지 못함 → 트리들의 모양이 서로 달라짐 → 트리 간 상관 $\rho \downarrow$ → 평균의 분산 $\rho\sigma^2 \downarrow$

Random Forest 알고리즘

- 1 **부트스트랩 표본**
 $b = 1, \dots, B$ 에 대해 학습 데이터에서 부트스트랩 표본 D^*_b 를 뽑는다
- 2 **무작위 변수 선택**
 트리를 키우며 각 노드에서 p 개 변수 중 m 개를 무작위로 뽑는다
- 3 **최적 분할**
 뽑힌 m 개 변수 안에서만 RSS(분류 : 지니) 를 최소로 하는 분할을 찾는다
- 4 **크게 키우기**
 최소 노드 크기 (nodesize) 에 도달할 때까지 반복 , 가지치기 없음
- 5 **결합**
 B 개 트리의 예측을 평균 (회귀) 또는 다수결 (분류) → OOB 오차도 함께 계산

Bagging 과의 차이는 단 하나

② 무작위 변수 선택

나머지는 모두 Bagging 과 같다 . 이 작은 변화가 트리 간 상관을 낮춘다 .

튜닝 모수

m (mtry), B (ntree), nodesize

작은 m : 다양성 $\uparrow$ 대신 개별 트리는 조금 나빠진다

 $m \downarrow$ 트리 간 상관 $\rho \downarrow$ 양상블 분산 $\downarrow$ (좋음) $m \downarrow$ 좋은 변수를 못 쓰는 분할 $\uparrow$ 개별 트리 bias $\uparrow$ (나쁨)**결과**적당한 m 에서 예측오차 최소 $\rightarrow$ OOB / CV 로 m 을 고른다


m 이 너무 작으면 (예 : $m = 1$) 잡음 변수로만 분할하는 경우가 많아져 트리가 쓸모없어진다 . 특히 잡음 변수가 많은 데이터에서 주의 .

Random Forest 의 핵심 = 개별 트리의 정확도를 조금 희생하고 , 그보다 훨씬 큰 “다양성 (낮은 ρ)” 을 얻는 거래

m 에 따라 상관 ρ , 분산, 예측오차는 어떻게 변할까 ?


$m \uparrow \rightarrow$ 상관 $\uparrow \rightarrow$ 분산 $\uparrow$

트리 간 상관 ρ 양상불 Variance



$m \downarrow \rightarrow$ bias $\uparrow$ · 오차는 m = 5~6 에서 최소

Bias² 예측오차 ($\sigma^2 + \text{Bias}^2 + \text{Var}$)



ρ : 0.621 (Bagging) $\rightarrow$ 0.542 (m=5) $\rightarrow$ 0.193 (m=1). 이 데이터에선 기본값 $p/3 = 3$ 보다 $m = 5 \sim 6$ 이 더 좋음 $\rightarrow m$ 은 튜닝 대상

시뮬레이션 설정은 앞과 동일 (Friedman #1, 10 개 중 5 개가 잡음 변수라 m 이 너무 작으면 bias 가 크게 증가). 트리 200 개.

숲을 해석하는 방법 : 변수 중요도 (VIP) 와 PDP

1 순열 중요도 (Permutation)

- OOB 데이터에서 변수 X_j 의 값만 무작위로 섞는다
- 섞기 전후 OOB 오차가 얼마나 커지는지 측정
- 많이 커질수록 중요한 변수
- R: %IncMSE (회귀), MeanDecreaseAccuracy (분류)

2 불순도 감소 (Impurity)

- 변수 X_j 로 분할할 때 줄어드는 RSS(지니) 를 모든 트리에서 합산
- 계산이 빠르다
- 값의 종류가 많은 변수를 과대평가하는 경향
- R: IncNodePurity (회귀), MeanDecreaseGini (분류)

VIP → “ 어떤 변수가 중요한가 ” , PDP(부분 의존도 그림) → “ 그 변수가 변할 때 예측이 어떻게 (방향 · 모양) 변하나 ” : 다른 변수들의 효과를 평균낸 상태에서 X_j 값에 따른 예측값의 변화를 그린다

R 실습 : randomForest 패키지 (조류 데이터 a1)

R CONSOLE

```
> library(randomForest)
> set.seed(1234)
# Bagging: mtry = 설명변수 개수 (11)
> bag.a1 <- randomForest(a1 ~ ., data=clean.algae[,1:12],
+                        mtry=11, ntree=500, importance=TRUE)
# Random Forest: mtry 기본값 = floor(11/3) = 3
> rf.a1 <- randomForest(a1 ~ ., data=clean.algae[,1:12],
+                      ntree=500, importance=TRUE)
> rf.a1                # OOB MSE, % Var explained
> plot(rf.a1)           # 트리 수에 따른 OOB 오차
> importance(rf.a1); varImpPlot(rf.a1) # VIP
> partialPlot(rf.a1, clean.algae[,1:12], x.var="P04") # PDP
> tuneRF(clean.algae[,1:11], clean.algae[,12], ntreeTry=500)
> predict(rf.a1, newdata=test)
```

mtry

분할마다 뽑는 변수 수 m. $mtry = p$ 이면 Bagging

ntree

트리 수 B (기본 500). 클수록 안정 , 과대적합 없음

clean.algae

randomForest 는 결측치를 받지 않음 → Part 1 에서 채운 데이터 사용

tuneRF()

OOB 오차 기준으로 mtry 를 자동 탐색

단일 트리 vs Bagging vs Random Forest

	단일 트리 (CART)	Bagging	Random Forest
Bias	낮음 (깊게 키우면)	단일 깊은 트리와 비슷	약간 증가할 수 있음
Variance	매우 큼	크게 감소	더 감소 ($\rho \downarrow$)
트리 간 상관	—	높음	낮음
해석	트리 그림 1 장으로 직관적	VIP · PDP 로 해석	VIP · PDP 로 해석
튜닝	cp (가지치기)	B	m (mtry), B
오차 추정	CV	OOB	OOB

실무에서 Random Forest 는 “튜닝을 거의 안 해도 잘 되는” 대표적인 기본 모형

Random Forest 의 장점과 한계

장점

- 단일 트리보다 예측 정확도가 크게 높다
- 튜닝 모수가 적고 기본값으로도 잘 작동
- OOB 오차로 별도 검증 없이 성능 추정
- 변수가 많아도 ($p > n$) 사용 가능, 병렬 계산 쉬움
- VIP·PDP 로 변수의 중요도와 효과 모양을 해석 가능

한계

- 단일 트리처럼 if-then 규칙 하나로 읽을 수는 없음
→ VIP·PDP 로 해석하는 한 단계가 더 필요
- 트리 수백 개 → 메모리 · 예측 시간 증가
- 학습 데이터 범위 밖으로 외삽 (extrapolation) 불가
- bias 는 줄이지 못한다 → bias 까지 줄이려면 Boosting

다음 단계 : Bagging/RF 는 “병렬로 평균” 해 분산을 줄이고 , Boosting 은 “순차적으로 보완” 해 bias 를 줄인다

SUMMARY

오늘의 핵심 정리

1 예측오차 분해

예측오차 = $\sigma^2 + \text{Bias}^2 + \text{Variance}$. 깊은 트리는 bias 는 낮고 variance 가 크다 .

2 평균의 힘

B 개를 평균하면 bias 는 그대로 , variance 는 줄어든다 → 예측오차 감소 (Bagging)

3 다양성의 힘

$\text{Var} = \rho\sigma^2 + (1-\rho)\sigma^2/B$. 트리 수를 늘려도 $\rho\sigma^2$ 은 남는다 → 상관 ρ 를 낮춰야 한다

4 Random Forest

분할마다 m 개 변수만 무작위로 → 트리들이 달라짐 → $\rho \downarrow \rightarrow$ 분산 $\downarrow$. m 은 OOB 로 튜닝